

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



KIỂM ĐỊNH TÍNH NGẪU NHIÊN
VÀ DỰ BÁO XÁC SUẤT XỔ SỐ KIẾN THIẾT

Chuyên ngành: KHOA HỌC DỮ LIỆU - THẠC SĨ QH2025

Học phần: CÁC PHƯƠNG PHÁP NGẪU NHIÊN VÀ ỨNG DỤNG

Giảng viên hướng dẫn: TS. TẠ CÔNG SƠN

Học viên thực hiện: TÔNG VIỆT TÚ - 25007845

Hà Nội – 09/2026

Lời mở đầu

Xổ số kiến thiết là một ví dụ điển hình của quá trình ngẫu nhiên trong thực tế, trong đó kết quả của mỗi kỳ quay về nguyên tắc được kỳ vọng là độc lập và không thể dự đoán một cách có hệ thống từ các kết quả đã quan sát trong quá khứ. Tuy nhiên, khi một lượng lớn dữ liệu lịch sử được tích lũy qua thời gian, một câu hỏi tự nhiên được đặt ra là liệu các kết quả xổ số thực tế có thực sự thể hiện đầy đủ các đặc trưng của một quá trình ngẫu nhiên hay vẫn tồn tại những sai lệch thống kê, sự phụ thuộc theo thời gian hoặc các cấu trúc có thể khai thác được. Trên thế giới đã có những nghiên cứu và công bố về học thuyết xổ số, tuy nhiên không có

Xuất phát từ vấn đề trên, bài nghiên cứu này phân tích dữ liệu kết quả xổ số kiến thiết dựa trên các kiến thức của môn học Các phương pháp ngẫu nhiên và ứng dụng, đồng thời cũng áp dụng các mô hình máy học hiện đại. Mục tiêu của nghiên cứu là kiểm chứng giả thuyết bằng dữ liệu thực nghiệm. Nghiên cứu hướng tới làm rõ ba câu hỏi chính: (i) kết quả xổ số có phù hợp với các đặc trưng kỳ vọng của một quá trình ngẫu nhiên hay không; (ii) các mô hình xác suất và học máy có khai thác được tín hiệu dự báo ổn định ngoài mẫu hay không; (iii) và nếu tồn tại tín hiệu, mức cải thiện đó có đủ để tạo ra một chiến lược có hiệu quả kinh tế sau khi tính đầy đủ chi phí tham gia và cơ cấu giải thưởng hay không.

Đối tượng và phương pháp nghiên cứu

Đối tượng và phạm vi nghiên cứu

Kết quả xổ số kiến thiết Miền Bắc, bao gồm toàn bộ các số trúng thưởng được công bố trong mỗi ngày quay số. Giải thưởng và thể lệ trúng thưởng được thu thập đúng theo công bố của công ty xổ số kiến thiết.

Dữ liệu được thu thập của xổ số kiến thiết Miền Bắc, do Miền Bắc sẽ chỉ có 1 kết quả duy nhất trong ngày, đảm bảo về tính toàn vẹn của thời gian (Miền Nam sẽ có nhiều kết quả trong ngày). Thời gian của kết quả đầy đủ từ năm 2007 đến hiện tại. Trong đó, giai đoạn hết năm 2022 được sử dụng làm thông tin lịch sử cho quá trình xây dựng mô hình. Giai đoạn 2023–2024 được sử dụng cho đánh giá và lựa chọn chiến lược, trong khi giai đoạn 2025–2026 được giữ lại làm tập kiểm định cuối cùng ngoài mẫu.

Mỗi ngày quay số bao gồm toàn bộ 27 kết quả thuộc các hạng giải từ giải đặc biệt đến giải bảy. Các kết quả được chuẩn hóa để phục vụ phân tích theo từng vị trí chữ số và theo phân hậu tố của số trúng thưởng.

Tần suất quan sát là theo ngày. Thứ tự thời gian của dữ liệu được giữ nguyên trong toàn bộ quá trình xây dựng và đánh giá mô hình; không thực hiện chia ngẫu nhiên dữ liệu huấn luyện và kiểm định.

Phương pháp nghiên cứu

- **Kiểm định tính ngẫu nhiên:** nghiên cứu phân tích phân phối chữ số, tính đồng đều, tính độc lập giữa các vị trí, sự phụ thuộc Markov, phụ thuộc theo độ trễ và mức độ ổn định của phân phối theo thời gian. Khi cần thiết, kích thước hiệu ứng và hiệu chỉnh cho nhiều phép kiểm định được xem xét song song với giá trị p .
- **Mô hình dự báo:** các phương pháp thống kê, mô hình xác suất và mô hình học máy được sử dụng để kiểm định tính ngẫu nhiên và đánh giá khả năng dự báo kết quả xổ số. Các phương pháp chính bao gồm kiểm định phân phối và tính độc lập,

mô hình tần suất, Rolling Frequency, mô hình Markov, Random Forest, XGBoost và CatBoost.

- **Đánh giá mô hình:** hiệu quả dự báo được đánh giá bằng các thước đo xác suất và xếp hạng như Brier score, log-loss, calibration và khả năng thu hồi chữ số thực tế trong nhóm dự báo có xác suất cao.
- **Đánh giá chiến lược:** xác suất dự báo được chuyển thành các tập số ứng viên và chiến lược lựa chọn vé. Hiệu quả được đánh giá thông qua số lần trúng thưởng, tổng chi phí, tổng tiền thưởng, lợi nhuận tích lũy và tỷ suất hoàn vốn (ROI), đồng thời được so sánh với chiến lược ngẫu nhiên hoặc các đường cơ sở thích hợp.

Mục lục

Lời mở đầu	i
Đối tượng và phương pháp nghiên cứu	ii
Danh mục viết tắt	vii
1 CƠ SỞ LÝ THUYẾT	1
1.1 Bài toán nghiên cứu	1
1.2 Ngẫu nhiên, đồng đều và độc lập	1
1.3 Kiểm định Chi-square, Cramér's V và hiệu chỉnh đa kiểm định	2
1.4 Xích Markov và phụ thuộc theo thời gian	2
1.4.1 Tính chất Markov	2
1.4.2 Markov nhị phân cho sự xuất hiện của chữ số	3
1.5 Các mô hình xác suất và tần suất cơ sở	4
1.5.1 Mô hình đồng đều	4
1.5.2 Tần suất mở rộng và cửa sổ trượt	4
1.6 Nền tảng học máy cho bài toán dự báo	4
1.6.1 Học có giám sát và đặc trưng trễ	4
1.6.2 Random Forest	5
1.6.3 Gradient Boosting	5
1.6.4 XGBoost	6
1.6.5 CatBoost	6
1.7 Đánh giá dự báo xác suất	6
1.7.1 Brier score và log loss	6
1.7.2 Calibration và Top- k recall	7
1.8 Đánh giá chiến lược và lợi nhuận	7

2	DỮ LIỆU VÀ QUY TRÌNH PHÂN TÍCH	8
2.1	Dữ liệu	8
2.2	Quy tắc trả thưởng và mục tiêu thực nghiệm	8
2.3	Quy trình	8
2.4	Chống rò rỉ thông tin	9
2.5	Tái lập	9
3	KIỂM ĐỊNH TÍNH NGẪU NHIÊN	10
3.1	Thiết kế giả thuyết và hiệu chỉnh đa kiểm định	10
3.2	Phân phối chữ số và phân phối đuôi số	10
3.3	Độc lập giữa các vị trí	11
3.4	Phụ thuộc Markov và phụ thuộc theo độ trễ	12
3.5	Ổn định theo thời gian và trùng đồng thời	13
3.6	Kết luận P1	15
4	MÔ HÌNH DỰ BÁO CHỮ SỐ	16
4.1	Biến mục tiêu và nguyên tắc đánh giá	16
4.2	Các mô hình	16
4.3	Kết quả định lượng	16
4.4	Diễn giải và giới hạn	19
4.5	Dự báo trực tiếp giải Đặc biệt	20
5	CHIẾN LƯỢC VÀ BACKTEST	21
5.1	Độ khó của mục tiêu giải Đặc biệt	21
5.2	Thí nghiệm rolling năm năm đối với giải Đặc biệt	22
5.2.1	Mục tiêu và giao thức	22
5.2.2	Kết quả thời gian chờ	23
5.2.3	Hàm ý đối với chiến thuật đầu tư	23
5.3	Thí nghiệm cố định huấn luyện trước năm 2021 và kiểm tra năm 2021– 2025	24

5.3.1	Thiết kế thực nghiệm	24
5.3.2	Chất lượng thứ hạng và tỷ lệ trúng giải Đặc biệt	25
5.3.3	Lần trúng đầu tiên, lần trúng thứ hai và thời gian chờ	26
5.3.4	ROI khi chỉ tính giải Đặc biệt	26
5.3.5	ROI khi tính toàn bộ cơ cấu giải thưởng	27
5.3.6	Các giải khác khi mua Top-10	27
5.3.7	Đánh giá tổng hợp	28
5.4	Thiết kế chiến lược	28
5.5	Chia tập và chỉ số	29
5.6	Kết quả P3	29
5.7	Chiến lược giải Bảy theo m	30
5.8	Diễn giải	32
6	KẾT QUẢ TỔNG HỢP VÀ THẢO LUẬN	33
6.1	Từ kiểm định đến dự báo	33
6.2	So sánh mô hình	33
6.3	Ý nghĩa thực tiễn	33
6.4	Giải Đặc biệt và chuyển hướng sang bài toán đầu tư	33
6.5	Hạn chế	35
7	KẾT LUẬN	36
	TÀI LIỆU THAM KHẢO	38

Danh mục viết tắt

Ký hiệu	Diễn giải
FDR	False Discovery Rate, tỷ lệ phát hiện sai
H_0	Giả thuyết không
IID	Independent and identically distributed
CDM	Categorical/Dirichlet–Multinomial
RF	Random Forest
LL	Log loss
ROI	Return on Investment
P1, P2, P3	Ba phần thực nghiệm của nghiên cứu

Danh sách hình vẽ

3.1	Phân phối chữ số theo vị trí trong toàn bộ dữ liệu.	11
3.2	Mức phụ thuộc giữa các vị trí chữ số.	12
3.3	Độ lệch của ma trận chuyển trạng thái Markov lag 1.	13
3.4	Phụ thuộc theo độ trễ 1–30 ngày bằng Cramér’s V.	13
3.5	Kết quả kiểm định gộp trong phân tích ổn định theo thời gian.	14
3.6	Độ ổn định của các thống kê theo giai đoạn.	14
3.7	Tỷ lệ trùng đồng thời nhiều giải theo năm.	14
4.1	So sánh Brier score trên validation.	17
4.2	Brier score theo mô hình.	18
4.3	Brier score theo vị trí chữ số.	18
4.4	Độ bao phủ Top- k theo vị trí.	18
4.5	Đường calibration được dựng lại từ calibration.csv.	19
4.6	Phân phối thứ hạng chữ số thực tế.	19
5.1	Lợi nhuận tích lũy của các pool trên validation.	30
5.2	Lợi nhuận tích lũy của các pool trên final test.	30
5.3	Lợi nhuận tích lũy của chiến lược tập trung giải Bảy trên validation.	31
5.4	Lợi nhuận tích lũy của chiến lược tập trung giải Bảy trên final test.	31
5.5	Độ nhảy lợi nhuận theo số đuôi m trên validation.	31
5.6	Độ nhảy lợi nhuận theo số đuôi m trên final test.	32

Danh sách bảng

3.1	Số kiểm định và kết quả sau hiệu chỉnh FDR	10
4.1	Brier score và log loss trên validation 2023–2024	17
5.1	Thời gian chờ đến lần trúng Đặc biệt đầu tiên trong cửa sổ rolling năm năm	23
5.2	Thứ hạng và tỷ lệ trúng giải Đặc biệt trên tập kiểm tra 2021–2025 . .	25
5.3	Thời gian chờ đến các lần trúng giải Đặc biệt trên tập kiểm tra 2021– 2025	26
5.4	ROI toàn bộ giải thưởng theo số lượng vé mua mỗi ngày	27
5.5	Tỷ lệ ngày trúng các giải khác và tiền thưởng khi mua Top-10	28
5.6	Backtest các cấu hình pool năm chữ số	29

Chương 1

CƠ SỞ LÝ THUYẾT

1.1 Bài toán nghiên cứu

Mỗi ngày, xổ số kiến thiết miền Bắc công bố nhiều kết quả thuộc các hạng giải khác nhau. Trong nghiên cứu này, mỗi kết quả được biểu diễn theo các chữ số ở từng vị trí, từ hàng chục nghìn đến hàng đơn vị khi vị trí tương ứng tồn tại. Hai nhóm câu hỏi được đặt ra. Thứ nhất, dữ liệu lịch sử có cung cấp bằng chứng thống kê về sự lệch khỏi cơ chế ngẫu nhiên, tính độc lập theo vị trí hoặc tính độc lập theo thời gian hay không. Thứ hai, nếu tồn tại các sai lệch nhỏ trong phân phối thực nghiệm, liệu chúng có đủ ổn định để các mô hình xác suất và học máy cải thiện dự báo ngoài mẫu và hỗ trợ xây dựng chiến lược có hiệu quả kinh tế hay không.

Đối với bài toán dự báo theo ngày, tại mỗi vị trí j và chữ số $d \in \{0, \dots, 9\}$, biến mục tiêu nhị phân được định nghĩa

$$Y_{t,j,d} = \begin{cases} 1, & \text{nếu chữ số } d \text{ xuất hiện tại vị trí } j \text{ trong ngày } t, \\ 0, & \text{ngược lại.} \end{cases}$$

Như vậy, bài toán dự báo chính có thể xem là bài toán multi-label gồm $5 \times 10 = 50$ mục tiêu nhị phân. Mô hình không chỉ đưa ra nhãn dự báo mà quan trọng hơn là ước lượng xác suất $\hat{p}_{t,j,d} = P(Y_{t,j,d} = 1 \mid \mathcal{F}_{t-1})$, trong đó $\mathcal{F}_{t-1}$ biểu diễn toàn bộ thông tin hợp lệ trước ngày dự báo.

1.2 Ngẫu nhiên, đồng đều và độc lập

Một chuỗi kết quả phù hợp với cơ chế ngẫu nhiên cơ bản khi phân phối chữ số không khác đáng kể so với phân phối kỳ vọng, quan hệ giữa các vị trí đủ yếu, kết quả trong quá khứ không tạo ra khả năng dự báo có hệ thống cho tương lai và các đặc trưng phân phối tương đối ổn định theo thời gian. Các khái niệm này cần được phân biệt: phân phối biên gần đồng đều không đồng nghĩa với độc lập, và độc lập giữa các vị trí không đảm bảo độc lập theo thời gian.

Trong kiểm định giả thuyết, việc không bác bỏ H_0 không phải là bằng chứng tuyệt đối rằng chuỗi hoàn toàn ngẫu nhiên; nó chỉ cho thấy dữ liệu hiện có chưa cung cấp đủ bằng chứng thống kê để bác bỏ giả thuyết không. Ngược lại, một sai lệch có ý nghĩa thống kê cũng chưa đồng nghĩa với khả năng dự báo hoặc khả năng sinh lợi thực tế. Vì vậy, báo cáo tách biệt ba lớp đánh giá: ý nghĩa thống kê, chất lượng dự báo ngoài mẫu và hiệu quả của chiến lược backtest.

1.3 Kiểm định Chi-square, Cramér's V và hiệu chỉnh đa kiểm định

Với tần suất quan sát O_k và tần suất kỳ vọng E_k , thống kê Pearson Chi-square được xác định bởi

$$\chi^2 = \sum_{k=1}^K \frac{(O_k - E_k)^2}{E_k}.$$

Kiểm định này được sử dụng để đánh giá mức độ phù hợp với phân phối kỳ vọng hoặc sự độc lập giữa các biến phân loại. Tuy nhiên, khi kích thước mẫu lớn, một khác biệt rất nhỏ cũng có thể tạo ra p -value thấp. Do đó, bên cạnh ý nghĩa thống kê cần báo cáo kích thước hiệu ứng.

Đối với hai biến phân loại, Cramér's V được dùng như một thước đo cường độ phụ thuộc:

$$V = \sqrt{\frac{\chi^2}{N \min(r-1, c-1)}},$$

trong đó N là số quan sát, r và c lần lượt là số hàng và số cột của bảng chéo. Giá trị V gần 0 cho thấy quan hệ thực nghiệm yếu, ngay cả khi kiểm định Chi-square có thể đạt ý nghĩa thống kê.

Do nghiên cứu thực hiện đồng thời nhiều kiểm định trên các vị trí, giải và độ trễ khác nhau, sử dụng trực tiếp ngưỡng $p < 0.05$ làm tăng nguy cơ phát hiện giả. Báo cáo áp dụng thủ tục Benjamini–Hochberg và sử dụng $q < 0.05$ để kiểm soát false discovery rate (FDR).

1.4 Xích Markov và phụ thuộc theo thời gian

1.4.1 Tính chất Markov

Xích Markov là mô hình xác suất cho một quá trình mà phân phối của trạng thái kế tiếp, khi biết trạng thái hiện tại, không phụ thuộc trực tiếp vào toàn bộ lịch sử trước

đó. Với xích Markov bậc một,

$$P(X_t = x_t \mid X_{t-1}, X_{t-2}, \dots, X_0) = P(X_t = x_t \mid X_{t-1}).$$

Nếu không gian trạng thái gồm các chữ số $\{0, 1, \dots, 9\}$, xác suất chuyển từ trạng thái i sang j được ký hiệu

$$p_{ij} = P(X_t = j \mid X_{t-1} = i),$$

và ma trận chuyển trạng thái là

$$\mathbf{P} = (p_{ij})_{10 \times 10}, \quad \sum_{j=0}^9 p_{ij} = 1.$$

Nếu kết quả giữa hai ngày thực sự độc lập, phân phối điều kiện theo trạng thái ngày trước không nên khác có hệ thống so với phân phối biên. Vì vậy, phân tích ma trận chuyển và kiểm định theo từng vị trí cung cấp một cách trực tiếp để kiểm tra dấu hiệu phụ thuộc thời gian bậc một.

1.4.2 Markov nhị phân cho sự xuất hiện của chữ số

Trong phần dự báo, nghiên cứu sử dụng biến trạng thái nhị phân cho từng cặp vị trí-chữ số: $Y_t \in \{0, 1\}$ cho biết chữ số đó có xuất hiện trong ngày hay không. Khi đó mô hình Markov ước lượng hai xác suất chính

$$P(Y_t = 1 \mid Y_{t-1} = 1), \quad P(Y_t = 1 \mid Y_{t-1} = 0).$$

Để tránh xác suất bằng 0 hoặc 1 do số lần chuyển trạng thái hữu hạn, xác suất được làm tròn Laplace. Chẳng hạn,

$$\hat{p}_{1 \rightarrow 1} = \frac{N_{11} + 1}{N_{10} + N_{11} + 2},$$

trong đó N_{ab} là số lần quan sát chuyển từ trạng thái a sang b . Có thể diễn giải phép làm tròn này dưới góc nhìn Bayes với tiên nghiệm $\text{Beta}(1, 1)$ cho mỗi xác suất chuyển nhị phân. Mô hình Markov vì vậy vừa là một baseline dự báo, vừa là phép kiểm tra thực nghiệm xem thông tin ngày liền trước có tạo ra cải thiện so với mô hình không điều kiện hay không.

1.5 Các mô hình xác suất và tần suất cơ sở

1.5.1 Mô hình đồng đều

Uniform baseline mô tả giả thuyết không có chữ số nào được ưu tiên. Khi một vị trí nhận m_j lượt quay hợp lệ trong ngày và mỗi lượt có xác suất 0.1 cho một chữ số cụ thể, xác suất chữ số đó xuất hiện ít nhất một lần là

$$p_j = 1 - (1 - 0.1)^{m_j} = 1 - 0.9^{m_j}.$$

Đây là mốc tham chiếu quan trọng: một mô hình phức tạp chỉ có giá trị dự báo khi cải thiện ổn định so với baseline đơn giản trên dữ liệu ngoài mẫu.

1.5.2 Tần suất mở rộng và cửa sổ trượt

Với một mục tiêu nhị phân Y_t , expanding frequency sử dụng toàn bộ lịch sử hợp lệ trước thời điểm dự báo:

$$\hat{p}_t = \frac{1}{t-1} \sum_{s < t} Y_s.$$

Rolling frequency chỉ sử dụng w quan sát gần nhất,

$$\hat{p}_t^{(w)} = \frac{1}{w} \sum_{s=t-w}^{t-1} Y_s.$$

Cửa sổ dài tạo ước lượng ổn định hơn nhưng phản ứng chậm với thay đổi; cửa sổ ngắn nhạy hơn với biến động gần đây nhưng có phương sai lớn hơn. Việc so sánh nhiều độ dài cửa sổ do đó giúp kiểm tra liệu dữ liệu có chứa tính không dừng hoặc tín hiệu ngắn hạn đủ mạnh để dự báo hay không.

1.6 Nền tảng học máy cho bài toán dự báo

1.6.1 Học có giám sát và đặc trưng trễ

Các mô hình học máy trong nghiên cứu thuộc nhóm học có giám sát. Từ dữ liệu lịch sử, thuật toán học một ánh xạ

$$f : \mathbf{x}_t \mapsto \hat{p}_t,$$

trong đó $\mathbf{x}_t$ chỉ chứa thông tin có sẵn trước thời điểm t . Các đặc trưng chính gồm trạng thái xuất hiện của chữ số tại các độ trễ 1, 2, 3, 7, 14 và 30 ngày cùng một số biến lịch

dạng chu kỳ. Việc dịch trễ đặc trưng đảm bảo không sử dụng kết quả của ngày cần dự báo.

Vì đây là dữ liệu theo thời gian, chia ngẫu nhiên train/test có thể gây rò rỉ thông tin và đánh giá quá lạc quan. Nghiên cứu do đó sử dụng chia tập theo thời gian: mô hình chỉ được huấn luyện trên giai đoạn quá khứ, lựa chọn cấu hình trên validation và đánh giá chiến lược cuối cùng trên giai đoạn tương lai chưa được dùng để lựa chọn mô hình.

1.6.2 Random Forest

Random Forest là phương pháp ensemble kết hợp nhiều cây quyết định. Mỗi cây được xây dựng từ mẫu bootstrap và chỉ xem xét một tập con đặc trưng tại mỗi phép chia. Với bài toán phân loại, xác suất cuối cùng có thể thu được bằng cách tổng hợp xác suất từ các cây:

$$\hat{p}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{p}_b(\mathbf{x}),$$

trong đó B là số cây. Cơ chế lấy mẫu và ngẫu nhiên hóa đặc trưng giúp giảm tương quan giữa các cây và thường làm giảm phương sai so với một cây quyết định đơn. Trong nghiên cứu, Random Forest đóng vai trò mô hình ML cơ sở để kiểm tra liệu quan hệ phi tuyến giữa các đặc trưng trễ có tạo ra thông tin dự báo ngoài mẫu hay không.

1.6.3 Gradient Boosting

Khác với Random Forest xây dựng nhiều cây tương đối độc lập, gradient boosting xây dựng mô hình theo trình tự. Ở vòng lặp m , một cây mới được thêm vào để giảm phần sai số còn lại của tổ hợp hiện tại:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta f_m(\mathbf{x}),$$

trong đó η là learning rate. Nhờ quá trình cộng dồn các weak learners, boosting có khả năng biểu diễn các quan hệ phi tuyến và tương tác phức tạp giữa các đặc trưng. Tuy nhiên, độ sâu cây, learning rate, số vòng boosting và regularization phải được kiểm soát để hạn chế overfitting.

1.6.4 XGBoost

XGBoost là một biến thể gradient-boosted trees có hàm mục tiêu tổng quát

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum_{k=1}^t \Omega(f_k),$$

trong đó l là hàm mất mát và $\Omega(f_k)$ là thành phần regularization cho độ phức tạp của cây. Đối với mục tiêu nhị phân của nghiên cứu, mô hình tối ưu binary logistic loss và trả về xác suất xuất hiện của từng chữ số. Các cơ chế shrinkage, subsampling, column sampling và regularization giúp cân bằng giữa khả năng học quan hệ phức tạp và nguy cơ khớp nhiều trong dữ liệu xỏ số.

1.6.5 CatBoost

CatBoost cũng thuộc họ gradient boosting trên cây quyết định. Thuật toán phát triển các cơ chế như ordered boosting nhằm giảm prediction shift và hạn chế một số dạng overfitting trong quá trình boosting. Trong bài toán này, CatBoost được sử dụng như một mô hình phi tuyến độc lập để đối chiếu với XGBoost trên cùng tập đặc trưng và cùng giao thức chia thời gian. Do dữ liệu đầu vào của thí nghiệm chủ yếu là đặc trưng số và nhị phân, mục tiêu so sánh không nằm ở khả năng xử lý biến phân loại đặc trưng của CatBoost mà ở khả năng học hàm xác suất khác nhau của hai thuật toán boosting.

1.7 Đánh giá dự báo xác suất

1.7.1 Brier score và log loss

Với dự báo xác suất $\hat{p}_i$ và nhãn $y_i \in \{0, 1\}$, Brier score được định nghĩa

$$\text{BS} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2.$$

Brier score càng thấp càng tốt và đánh giá trực tiếp độ chính xác của xác suất. Log loss được xác định bởi

$$\text{LL} = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)].$$

Log loss phạt mạnh các dự báo tự tin nhưng sai. Vì mục tiêu cuối cùng cần xếp hạng chữ số và xây dựng chiến lược từ xác suất, hai thước đo này phù hợp hơn việc chỉ sử dụng accuracy tại một ngưỡng phân loại cố định.

1.7.2 Calibration và Top- k recall

Một mô hình được xem là hiệu chỉnh tốt nếu trong nhóm các dự báo có xác suất xấp xỉ p , tỷ lệ xảy ra quan sát được cũng xấp xỉ p . Calibration vì vậy trả lời câu hỏi khác với ranking: mô hình có thể xếp hạng tốt nhưng xác suất dự báo vẫn quá cao hoặc quá thấp.

Đối với mỗi vị trí, các chữ số được sắp giảm dần theo xác suất. Top- k recall đo tỷ lệ chữ số thực tế được bao phủ bởi k lựa chọn có xác suất cao nhất. Chỉ số này nói trực tiếp phần dự báo với phần chiến lược, bởi số lượng chữ số được giữ lại tại từng vị trí quyết định kích thước không gian vé ứng viên và chi phí đầu tư.

1.8 Đánh giá chiến lược và lợi nhuận

Đối với một chiến lược mua tập vé S_t trong ngày t , lợi nhuận được tính tổng quát bởi

$$\Pi_t = R_t(S_t) - c|S_t|,$$

trong đó c là giá mỗi vé, $|S_t|$ là số vé mua và $R_t(S_t)$ là tổng tiền thưởng thực tế theo toàn bộ các quy tắc giải mà các vé trong S_t đạt được. Tỷ suất hoàn vốn được tính

$$\text{ROI} = \frac{\sum_t \Pi_t}{\sum_t c|S_t|}.$$

Do cơ cấu giải thưởng phụ thuộc số chữ số khớp và loại giải, không sử dụng một mức thưởng cố định cho mọi lần trúng. Việc đánh giá chiến lược phải thực hiện trên giai đoạn ngoài mẫu, đồng thời xem xét lợi nhuận tích lũy, ROI, tần suất trúng và mức biến động thay vì kết luận từ một vài ngày có giải thưởng lớn.

Tách biệt giai đoạn lựa chọn chiến lược và giai đoạn final test là điều kiện quan trọng để hạn chế selection bias. Một cấu hình có lợi nhuận cao trên validation chỉ được xem là có bằng chứng thực nghiệm mạnh hơn khi tiếp tục duy trì kết quả trên giai đoạn final test chưa tham gia vào quá trình lựa chọn.

Chương 2

DỮ LIỆU VÀ QUY TRÌNH PHÂN TÍCH

2.1 Dữ liệu

Dữ liệu gồm 191 511 dòng kết quả, 7 093 ngày, từ 01/01/2007 đến 06/09/2026. Tập dữ liệu bao phủ 27 giải mỗi ngày, gồm Đặc biệt, giải Nhất đến giải Bảy. Kết quả được chuẩn hóa theo ngày, loại giải và thứ tự xuất hiện, nhưng vẫn giữ nguyên độ dài công bố của từng giải. Cụ thể, các giải Sáu và Bảy không được biến đổi thành chuỗi năm chữ số khi xây dựng mục tiêu, kiểm định hoặc mô hình; các quy tắc khớp hai, ba và bốn chữ số được xử lý riêng ở bước backtest. Hai chữ số cuối được giữ trong miền $00, \dots, 99$.

2.2 Quy tắc trả thưởng và mục tiêu thực nghiệm

Mỗi vé được biểu diễn bởi một số có năm chữ số. Giải Đặc biệt, giải Nhất, Nhì và Ba yêu cầu khớp đủ năm chữ số; giải Tư và Năm khớp bốn chữ số; giải Sáu khớp ba chữ số; giải Bảy khớp hai chữ số. Phụ Đặc biệt và Khuyến khích Đặc biệt được xử lý theo quy định riêng, trong đó ký hiệu của giải Đặc biệt không được dùng làm đặc trưng dự báo. Một vé có thể đồng thời nhận nhiều giải khi các điều kiện hậu tố cùng thỏa mãn.

Mục tiêu được chia thành hai lớp: (i) dự báo pool chữ số theo từng vị trí, tức chữ số nào có khả năng xuất hiện trong 27 giải; (ii) dự báo trực tiếp số năm chữ số theo từng giải, chủ yếu để đánh giá tính khả thi và mức độ khó của bài toán.

2.3 Quy trình

1. Kiểm tra ngày, bản ghi trùng và tính hợp lệ.
2. Tách chữ số theo vị trí và tạo biên đuôi số.
3. Phân tích phân phối, độc lập theo vị trí và phụ thuộc thời gian.
4. Kiểm tra ổn định theo các giai đoạn.
5. Tạo mục tiêu theo ngày: chữ số bằng 1 nếu xuất hiện trong ít nhất một của 27 kết

quả.

6. Huấn luyện/cập nhật mô hình theo walk-forward.

7. Đánh giá Brier, log loss, top- k , calibration, thứ hạng và lợi nhuận.

2.4 Chống rò rỉ thông tin

Dự báo ngày t chỉ sử dụng dữ liệu trước t ; kết quả ngày t chỉ cập nhật mô hình sau khi dự báo được tạo. Validation 2023–2024 dùng để so sánh và khóa cấu hình. Final test 2025–2026 chỉ dùng cho đánh giá cuối cùng và không được dùng để chọn lại mô hình hay chiến lược. Riêng thí nghiệm dự báo trực tiếp giải Đặc biệt được thiết kế theo giao thức độc lập: toàn bộ mô hình học máy được huấn luyện cố định bằng dữ liệu đến hết ngày 31/12/2020, sau đó đánh giá trên giai đoạn 2021–2025; các mô hình thống kê được cập nhật tuần tự nhưng tại mỗi ngày chỉ sử dụng lịch sử trước ngày đó.

2.5 Tái lập

Mã nguồn nằm trong `experiments/`; kết quả được tổ chức tương ứng trong `artifacts/p1_statistics/`, `artifacts/p2_models/` và `artifacts/p3_strategies/`.

Chương 3

KIỂM ĐỊNH TÍNH NGẪU NHIÊN

3.1 Thiết kế giả thuyết và hiệu chỉnh đa kiểm định


Phần P1 kiểm tra liệu dữ liệu có lệch khỏi các mô hình ngẫu nhiên cơ bản hay không. Mỗi nhóm kiểm định được thực hiện trên dữ liệu gộp và/hoặc theo vị trí chữ số, sau đó p-value được hiệu chỉnh bằng thủ tục Benjamini–Hochberg với ngưỡng $q < 0,05$. Cách làm này hạn chế kết luận sai do số lượng kiểm định lớn.

Bảng 3.1. Số kiểm định và kết quả sau hiệu chỉnh FDR

Nhóm kiểm định	Số kiểm định	Bác bỏ H_0
Phân phối chữ số	45	1
Phân phối đuôi số	28 hợp lệ	5
Độc lập giữa vị trí	90	0
Markov lag 1	90	0
Phụ thuộc lag 1–30	2700	0
Ổn định theo giai đoạn	4050	0

3.2 Phân phối chữ số và phân phối đuôi số


Kiểm định χ^2 được dùng để so sánh tần suất chữ số quan sát với phân phối đều. Hình 3.1 cho thấy các sai khác biên trong dữ liệu gộp; chỉ một trong 45 kiểm định còn ý nghĩa sau FDR. Với các đuôi số, chỉ 28 kiểm định đủ điều kiện và có 5 bác bỏ H_0 . Đây là các phát hiện cục bộ, chưa đủ để kết luận tồn tại quy luật tổng quát.



Hình 3.1. Phân phối chữ số theo vị trí trong toàn bộ dữ liệu.

3.3 Độc lập giữa các vị trí


Kiểm định độc lập và thống kê liên hợp được dùng để xem chữ số ở các vị trí có liên hệ vượt quá mức kỳ vọng hay không. Không có bác bỏ nào trong 90 kiểm định sau FDR. Hình 3.2 trực quan hóa mức phụ thuộc rất nhỏ giữa các vị trí.




Hình 3.2. Mức phụ thuộc giữa các vị trí chữ số.

3.4 Phụ thuộc Markov và phụ thuộc theo độ trễ

P1 kiểm tra cả phụ thuộc chuyển trạng thái ở lag 1 và phụ thuộc giữa các ngày ở lag 1–30. Không có kiểm định Markov nào trong 90 kiểm định bị bác bỏ; hình 3.3 cho thấy độ lệch chuyển trạng thái không tạo cấu trúc nổi bật. Tương tự, thống kê Cramér's V theo các độ trễ không cho thấy tín hiệu bền vững (Hình 3.4).




Hình 3.3. Độ lệch của ma trận chuyển trạng thái Markov lag 1.




Hình 3.4. Phụ thuộc theo độ trễ 1–30 ngày bằng Cramér's V.

3.5 Ổn định theo thời gian và trùng đồng thời


Phân tích ổn định chia chuỗi theo giai đoạn và lặp lại các kiểm định chính. Không có bác bỏ nào trong 4050 kiểm định; Hình 3.6 tóm tắt kết quả ý nghĩa theo từng nhóm. Tỷ lệ ngày có ít nhất hai giải cùng chứa một đuôi số là 62,63%; ít nhất ba giải là 0,25%; ít nhất bốn giải xấp xỉ 0,00%. Đây là mô tả cơ chế chồng lấn của nhiều giải, không phải bằng chứng dự báo.



Hình 3.5. Kết quả kiểm định gộp trong phân tích ổn định theo thời gian.



Hình 3.6. Độ ổn định của các thống kê theo giai đoạn.



Hình 3.7. Tỷ lệ trùng đồng thời nhiều giải theo năm.

3.6 Kết luận P1

Các kiểm định cung cấp bằng chứng nhất quán với một quá trình gần ngẫu nhiên ở mức độ cần thiết cho dự báo thực hành. Một vài sai lệch cục bộ có thể xuất hiện do kích thước mẫu lớn, do cơ chế nhiều giải trong cùng ngày hoặc do biến thiên ngẫu nhiên. Vì vậy, P1 chỉ cho phép chuyển sang kiểm tra dự báo ngoài mẫu; không cho phép khẳng định có lợi thế chơi.

Chương 4

MÔ HÌNH DỰ BÁO CHỮ SỐ

4.1 Biện mục tiêu và nguyên tắc đánh giá

Với mỗi ngày, vị trí và chữ số, mục tiêu bằng 1 nếu chữ số xuất hiện trong ít nhất một của 27 kết quả, bằng 0 nếu không xuất hiện. Như vậy, P2 là bài toán phân loại nhị phân nhiều đầu ra với 50 nhãn, không phải bài toán đoán một số duy nhất từ 00 đến 99.

Dữ liệu phát triển kết thúc năm 2022; validation gồm 723 ngày của 2023–2024; final test gồm 606 ngày của 2025–2026. Các thước đo chính là Brier score và log loss trên 50 nhãn. Các chỉ số Top- k được tính trên thứ hạng chữ số trong từng vị trí; do mỗi vị trí có thể có nhiều chữ số xuất hiện, Top- k không được diễn giải như xác suất trúng một vé cụ thể.

4.2 Các mô hình

Đường cơ sở Uniform–27-IID dùng xác suất lý thuyết $1 - (9/10)^{27}$ cho mọi chữ số ở mọi vị trí. Nhóm thống kê gồm Expanding Beta, Rolling Beta với cửa sổ 30, 90 và 365 ngày, Dirichlet daily và Markov presence. Nhóm học máy gồm Random Forest, CatBoost và XGBoost. Tất cả mô hình được chạy walk-forward: dự báo ngày t chỉ dùng thông tin trước t .


4.3 Kết quả định lượng


Bảng 4.1 sử dụng trực tiếp các giá trị trong `model_summary.csv`, được sinh từ pipeline đánh giá 50 nhãn. Do đó, các con số trong bảng được làm tròn từ CSV thay vì sao chép mô tả văn bản cũ.

Bảng 4.1. Brier score và log loss trên validation 2023–2024


Mô hình	Brier score	Log loss
Uniform–27-IID	0,106336	0,356877
Expanding Beta	0,106351	0,356916
Rolling Beta 365	0,106527	0,357810
Dirichlet daily	0,106341	0,356877
Markov presence	0,106389	0,357095
Random Forest	0,107159	0,360805
CatBoost	0,106763	0,358974
XGBoost	0,108023	0,364530
Rolling Beta 90	0,107390	0,361708
Rolling Beta 30	0,109681	0,369545

Trên validation, Dirichlet daily gần như tương đương Uniform và Expanding Beta; CatBoost là mô hình học máy tốt nhất nhưng vẫn kém nhóm cơ sở theo Brier. Trên final test, Expanding Beta đạt Brier 0,104579 và log loss 0,351395, còn Uniform đạt 0,104589 và 0,351453. Khoảng cách rất nhỏ, không phải bằng chứng về lợi thế kinh tế.


**Hình 4.1.** So sánh Brier score trên validation.




Hình 4.2. Brier score theo mô hình.




Hình 4.3. Brier score theo vị trí chữ số.



Hình 4.4. Độ bao phủ Top- k theo vị trí.



Hình 4.5. Đường calibration được dựng lại từ calibration.csv.



Hình 4.6. Phân phối thứ hạng chữ số thực tế.

4.4 Diễn giải và giới hạn

Các đường Top- k gần đường cơ sở lý thuyết: Top 1 bao phủ xấp xỉ 10%, Top 3 khoảng 30%, Top 5 khoảng 50%. Điều này là hệ quả tự nhiên của mười chữ số gần đối xứng, không cho thấy mô hình nhận diện được chữ số “sắp ra”. Mô hình có Brier thấp hơn rất ít vẫn có thể không tạo được lợi nhuận sau khi tính chi phí, số lượng vé và cơ cấu trả thưởng.

4.5 Dự báo trực tiếp giải Đặc biệt

Để kiểm tra riêng khả năng dự báo đúng một số gồm năm chữ số, nghiên cứu thực hiện thêm một giao thức ngoài mẫu độc lập với bài toán pool chữ số. Giai đoạn phát triển gồm toàn bộ kết quả Đặc biệt từ năm 2007 đến hết ngày 31/12/2020; giai đoạn kiểm tra kéo dài từ ngày 01/01/2021 đến ngày 31/12/2025. Sau khi loại các ngày không có kết quả Đặc biệt hợp lệ, tập kiểm tra còn 1 806 ngày. Mỗi ngày, mô hình sinh thứ hạng cho 100 000 số năm chữ số và lưu các dự báo Top-1 đến Top-10.

Mười cấu hình được so sánh gồm Random đều, Expanding Frequency, Rolling Frequency với cửa sổ 30, 90, 180, 365 và 730 ngày, Markov theo vị trí chữ số, CatBoost theo vị trí và XGBoost theo vị trí. CatBoost và XGBoost chỉ được huấn luyện bằng dữ liệu trước năm 2021. Với các mô hình thống kê, trạng thái được cập nhật sau mỗi ngày kiểm tra bằng kết quả đã quan sát của ngày trước đó. Giao thức này mô phỏng đúng tình huống dự báo tuần tự và không sử dụng kết quả hiện tại hoặc tương lai để tạo dự báo.

Khác với mục tiêu pool ở trên, đánh giá trực tiếp sử dụng thứ hạng của toàn bộ số năm chữ số. Vì vậy, các chỉ số Brier và log loss của thí nghiệm này không được gộp với bảng P2; các chỉ số chính là thứ hạng trung bình của số thực tế, tỷ lệ trúng Top- k , thời gian chờ đến lần trúng đầu tiên và ROI của chiến lược mua vé.

Chương 5

CHIẾN LƯỢC VÀ BACKTEST

5.1 Độ khó của mục tiêu giải Đặc biệt

Mục tiêu giải Đặc biệt phải được tách khỏi mục tiêu dự báo chữ số thông thường ngay từ đầu. Một vé hợp lệ có dạng gồm một ký hiệu (số quay bổ sung) và một số năm chữ số, chẳng hạn 05-34534. Vì vậy, để nhận giải Đặc biệt trị giá 500 triệu VND, vé phải đồng thời thỏa mãn hai điều kiện: (i) năm chữ số là đúng 34534 và (ii) ký hiệu là một trong bốn ký hiệu trúng thưởng được quay từ tổng số 20 ký hiệu.

Với giả định các chữ số và ký hiệu được sinh độc lập và đồng đều, xác suất của một vé cụ thể được tính như sau:

$$\begin{aligned}P(\text{đúng 5 chữ số}) &= \frac{1}{100\,000} = 0,001\%, \\P(\text{đúng ký hiệu} \mid \text{đúng 5 chữ số}) &= \frac{4}{20} = 20\%, \\P(\text{giải Đặc biệt}) &= \frac{1}{100\,000} \times \frac{4}{20} = \frac{1}{500\,000} = 0,0002\%.\end{aligned}$$

Như vậy, việc khớp đủ năm chữ số mới chỉ là điều kiện cần; khi bổ sung điều kiện ký hiệu, xác suất trúng thực sự giảm thêm năm lần. Số lượt quay kỳ vọng để một vé đơn lẻ trúng là 500 000 lượt, tương đương khoảng 1 370 năm nếu mỗi ngày có một lượt quay. Với m vé khác nhau trong một ngày, xác suất lý thuyết trong ngày là $m/500\,000$.

Trong bộ dữ liệu sử dụng cho báo cáo, trường ký hiệu của giải Đặc biệt chưa được lưu thành một biến quan sát riêng; các thí nghiệm mô hình và backtest trực tiếp vì vậy chỉ đánh giá phần năm chữ số. Phép tính trên là bước hiệu chỉnh xác suất lý thuyết cho mục tiêu giải thưởng đầy đủ, chứ không được diễn giải là một lần trúng ký hiệu đã quan sát trong backtest. Chẳng hạn, trong 1 806 ngày kiểm tra 2021–2025, một vé Top-1 có số lần trúng kỳ vọng 0,003612 và xác suất có ít nhất một lần trúng chỉ khoảng 0,361%; trong 5 281 ngày của thí nghiệm rolling năm năm, các giá trị tương ứng là 0,010562 và khoảng 1,051%. Với Top-10, xác suất có ít nhất một lần trúng trong hai giai đoạn lần lượt chỉ khoảng 3,548% và 10,023%.

Kết quả này cung cấp động cơ cho việc chuyển từ câu hỏi “dự đoán một số Đặc biệt” sang câu hỏi “chiến thuật mua vé có tạo ra lợi nhuận hay không”. Các kiểm định

chi tiết đối với Top-1–Top-10, thời gian chờ, lần trúng thứ hai và ROI được trình bày trước khi đánh giá các chiến lược P3 ở các mục tiếp theo.

5.2 Thí nghiệm rolling năm năm đối với giải Đặc biệt

5.2.1 Mục tiêu và giao thức

Để kiểm định trực tiếp độ khó của mục tiêu giải Đặc biệt, một thí nghiệm riêng được thực hiện cho bài toán dự báo số gồm năm chữ số. Với ngày dự đoán t , mô hình chỉ được sử dụng các kết quả Đặc biệt xuất hiện trước t và nằm trong năm năm lịch liền trước. Như vậy, thông tin của tương lai không được sử dụng trong quá trình dự báo.

Thí nghiệm được thực hiện trên dữ liệu từ ngày 01/01/2007 đến ngày 06/09/2026. Giai đoạn đánh giá bắt đầu từ ngày 01/01/2012, gồm 5.281 ngày có kết quả. Tám mô hình được so sánh gồm Random đều, Markov theo vị trí và các mô hình tần suất rolling với cửa sổ 30, 90, 180, 365, 730 và 1.825 ngày. Mỗi mô hình tạo danh sách Top- m , với $m = 1, \dots, 10$, gồm các số năm chữ số có xác suất dự báo cao nhất. Các số có chữ số đầu bằng 0 vẫn được giữ nguyên dưới dạng chuỗi năm chữ số.

Nếu lựa chọn ngẫu nhiên một số trong 100.000 số có thể, xác suất trúng với Top- m trong một ngày là

$$p_m = \frac{m}{100\,000}.$$

Do đó, số lần trúng kỳ vọng sau N ngày là Np_m , còn xác suất có ít nhất một lần trúng là

$$P_m(\text{ít nhất một lần trúng}) = 1 - (1 - p_m)^N.$$

Các đại lượng này được dùng làm đường cơ sở để phân biệt một lần trúng ngẫu nhiên với bằng chứng về lợi thế dự báo.

Tuy nhiên, p_m ở trên mới chỉ là xác suất khớp phần năm chữ số. Nếu yêu cầu đúng thêm ký hiệu giải Đặc biệt theo cấu trúc 4/20, xác suất trúng đầy đủ của Top- m phải được hiệu chỉnh thành

$$p_m^{\text{đầy đủ}} = \frac{m}{100\,000} \times \frac{4}{20} = \frac{m}{500\,000}.$$

Do trường ký hiệu không có trong dữ liệu, các bảng thực nghiệm tiếp theo vẫn báo cáo kết quả khớp năm chữ số; $p_m^{\text{đầy đủ}}$ được sử dụng để diễn giải mức khó lý thuyết của giải thưởng hoàn chỉnh.

5.2.2 Kết quả thời gian chờ

Bảng 5.1 trình bày kết quả ở hai cấu hình có ý nghĩa thực tiễn nhất: chỉ mua một số đứng đầu và mua mười số đứng đầu mỗi ngày. “Thời gian chờ” được tính từ ngày bắt đầu dự đoán đến lần trúng đầu tiên; số lượt trong ngoặc là thứ tự ngày dự đoán có trúng.

Bảng 5.1. Thời gian chờ đến lần trúng Đặc biệt đầu tiên trong cửa sổ rolling năm năm

Mô hình	Top-1	Top-10	Ngày trúng Top-10	Chờ (ngày / lượt)	ROI Top-10
Markov 5 năm	0/5.281	0/5.281	–	–	-100,00%
Tần suất 30 ngày	0/5.281	0/5.281	–	–	-100,00%
Tần suất 90 ngày	0/5.281	1/5.281	31/12/2021	3.652 / 3.591	-95,27%
Tần suất 180 ngày	0/5.281	1/5.281	07/09/2021	3.537 / 3.476	-95,27%
Tần suất 365 ngày	0/5.281	0/5.281	–	–	-100,00%
Tần suất 730 ngày	0/5.281	0/5.281	–	–	-100,00%
Tần suất 1.825 ngày	0/5.281	1/5.281	07/10/2018	2.471 / 2.444	-95,27%
Random đều	0/5.281	1/5.281	23/05/2021	3.430 / 3.369	-95,27%

Không có mô hình nào trúng Top-1 trong toàn bộ 5.281 ngày đánh giá. Với Top-10, ba mô hình tần suất và đường cơ sở Random đều mỗi mô hình chỉ trúng một lần; các mô hình còn lại không trúng. Trong cùng số ngày, Top-1 ngẫu nhiên có số lần trúng kỳ vọng 0,05281 và xác suất có ít nhất một lần trúng khoảng 5,14%. Với Top-10, số lần trúng kỳ vọng là 0,52810 và xác suất có ít nhất một lần trúng khoảng 41,03%. Vì vậy, việc một số mô hình Top-10 trúng một lần là hoàn toàn phù hợp với dao động ngẫu nhiên của đường cơ sở, chưa tạo thành bằng chứng về khả năng dự báo.

5.2.3 Hàm ý đối với chiến thuật đầu tư

Kết quả trên cho thấy việc tối ưu thứ hạng của một số Đặc biệt cụ thể không tạo ra lợi thế kinh tế. Nếu chỉ xét giải Đặc biệt, một vé có giá 10.000 VND có giá trị trả thưởng

kỳ vọng

$$\mathbb{E}[R] = \frac{500\,000\,000}{500\,000} = 1\,000 \text{ VND},$$

suy ra lợi nhuận kỳ vọng là $1\,000 - 10\,000 = -9\,000$ VND/vé và ROI kỳ vọng là -90% . Mua m vé mỗi ngày làm chi phí tăng tuyến tính nhưng không thay đổi ROI kỳ vọng. Đây là giá trị lý thuyết của giải Đặc biệt 500 triệu VND; các bảng backtest bên dưới chỉ kiểm tra phần năm chữ số và giữ nguyên lịch trả thưởng được mã hóa trong thí nghiệm, vì dữ liệu chưa có trường ký hiệu bổ sung.

Do đó, hướng nghiên cứu tiếp theo không tiếp tục tìm một “số Đặc biệt chắc chắn”, mà chuyển sang đánh giá chiến thuật đầu tư dưới ngân sách cố định. Mỗi chiến thuật được khóa trên validation, sau đó đánh giá một lần trên final test. Các tiêu chí gồm tỷ lệ ngày có ít nhất một lần trúng, lợi nhuận tích lũy, ROI, thời gian hòa vốn và độ ổn định giữa các giai đoạn. Việc đối sánh phải sử dụng toàn bộ cơ cấu giải thưởng hợp lệ, vì các giải thấp và các dạng khớp một phần có thể làm thay đổi giá trị kỳ vọng so với chiến lược chỉ nhắm vào giải Đặc biệt.

5.3 Thí nghiệm cố định huấn luyện trước năm 2021 và kiểm tra năm 2021–2025

5.3.1 Thiết kế thực nghiệm

Thí nghiệm này được xây dựng để trả lời câu hỏi thực tế hơn: nếu mô hình được huấn luyện bằng toàn bộ dữ liệu lịch sử trước năm 2021, trong năm năm tiếp theo mô hình có thể trúng giải Đặc biệt với tần suất và hiệu quả kinh tế như thế nào. Giai đoạn huấn luyện/phát triển sử dụng dữ liệu từ ngày 01/01/2007 đến ngày 31/12/2020. Giai đoạn kiểm tra bắt đầu từ ngày 01/01/2021 và kết thúc ngày 31/12/2025. Sau khi loại các ngày thiếu hoặc không hợp lệ, có 1 806 ngày dự đoán.

Mỗi mô hình tạo thứ hạng cho toàn bộ 100 000 số năm chữ số và đánh giá các ngưỡng Top- k , với $k \in \{1, \dots, 10\}$. Các mô hình gồm Random đều, Expanding Frequency, Rolling Frequency với cửa sổ 30, 90, 180, 365 và 730 ngày, Markov theo vị trí chữ số, CatBoost theo vị trí và XGBoost theo vị trí. CatBoost và XGBoost được huấn luyện cố định một lần trên dữ liệu đến hết năm 2020. Ngược lại, các mô hình thống kê được cập nhật prequential: tại ngày t , chỉ các kết quả trước t được phép tham gia vào phân phối dự báo; kết quả của ngày t chỉ được đưa vào trạng thái sau khi dự báo đã được sinh ra.

Đối với mỗi ngưỡng Top- k , chi phí là 10 000 VND cho một vé mỗi ngày. Tiền thưởng được tính đồng thời trên toàn bộ 27 kết quả trong ngày theo đúng loại giải: giải Đặc biệt, giải Nhất, Nhì, Ba yêu cầu khớp năm chữ số; giải Tư và Năm khớp bốn chữ số; giải Sáu khớp ba chữ số; giải Bảy khớp hai chữ số. Do đó, bảng ROI “toàn bộ giải” bao gồm cả các giải thấp hơn, trong khi ROI “chỉ giải Đặc biệt” chỉ tính khoản thưởng Đặc biệt.

5.3.2 Chất lượng thứ hạng và tỷ lệ trúng giải Đặc biệt

Bảng 5.2 cho thấy thứ hạng trung bình của số Đặc biệt thực tế gần 50 000 ở tất cả mô hình. Không mô hình nào trúng Top-1 trong 1 806 ngày kiểm tra. Tỷ lệ Top-10 cao nhất chỉ là một ngày trên 1 806 ngày, tương đương 0,055%.

Bảng 5.2. Thứ hạng và tỷ lệ trúng giải Đặc biệt trên tập kiểm tra 2021–2025

Mô hình	Hạng TB	Top-1	Top-5	Top-10	Top-20	Top-50	Top-100
CatBoost	49 268,37	0,000%	0,000%	0,055%	0,055%	0,055%	0,111%
Expanding Frequency	50 484,06	0,000%	0,000%	0,000%	0,000%	0,000%	0,000%
Markov	50 222,72	0,000%	0,000%	0,055%	0,055%	0,055%	0,111%
Rolling Frequency 180	50 257,31	0,000%	0,055%	0,055%	0,055%	0,055%	0,166%
Rolling Frequency 30	49 732,20	0,000%	0,000%	0,000%	0,000%	0,055%	0,055%
Rolling Frequency 365	50 428,76	0,000%	0,000%	0,000%	0,000%	0,000%	0,055%
Rolling Frequency 730	50 159,11	0,000%	0,000%	0,000%	0,000%	0,055%	0,055%
Rolling Frequency 90	49 998,51	0,000%	0,000%	0,055%	0,055%	0,055%	0,055%
Random đều	51 708,51	0,000%	0,000%	0,055%	0,055%	0,055%	0,055%
XGBoost	49 685,78	0,000%	0,000%	0,000%	0,000%	0,000%	0,000%

Nhìn theo toàn bộ dãy Top-1 đến Top-10, số ngày trúng giải Đặc biệt lần lượt là: CatBoost (0, 0, 0, 0, 0, 0, 0, 1, 1, 1); Expanding Frequency (0, 0, 0, 0, 0, 0, 0, 0, 0, 0); Markov (0, 0, 0, 0, 0, 0, 0, 1, 1, 1); Rolling Frequency 180 (0, 1, 1, 1, 1, 1, 1, 1, 1, 1); Rolling Frequency 30, 365, 730 và XGBoost đều bằng 0 ở mọi ngưỡng; Rolling Frequency 90 là (0, 0, 0, 0, 0, 0, 0, 0, 0, 1); Random đều là (0, 0, 0, 0, 0, 1, 1, 1, 1, 1). Như vậy, mô hình thống kê có kết quả tốt nhất ở ngưỡng Top-2 là Rolling Frequency 180, nhưng chỉ tạo ra một lần trúng duy nhất.

5.3.3 Lần trúng đầu tiên, lần trúng thứ hai và thời gian chờ

Bảng 5.3 báo cáo lần trúng đầu tiên tại ngưỡng sớm nhất trong Top-1–Top-10. Thời gian chờ được tính theo số ngày lịch kể từ ngày 01/01/2021; “lượt dự đoán” là thứ tự của ngày kiểm tra có kết quả trúng. Không có mô hình nào có lần trúng thứ hai trong toàn bộ năm năm kiểm tra.

Bảng 5.3. Thời gian chờ đến các lần trúng giải Đặc biệt trên tập kiểm tra 2021–2025

Mô hình	Top sớm nhất	Ngày trúng đầu tiên	Chờ lịch	Lượt dự đoán	Lần thứ hai
CatBoost	Top-8	15/04/2024	1 200	1 185	Không có
Expanding Frequency	–	–	–	–	Không có
Markov	Top-8	09/08/2024	1 316	1 301	Không có
Rolling Frequency 180	Top-2	07/09/2021	249	246	Không có
Rolling Frequency 30	–	–	–	–	Không có
Rolling Frequency 365	–	–	–	–	Không có
Rolling Frequency 730	–	–	–	–	Không có
Rolling Frequency 90	Top-10	31/12/2021	364	361	Không có
Random đều	Top-6	23/05/2021	142	139	Không có
XGBoost	–	–	–	–	Không có

5.3.4 ROI khi chỉ tính giải Đặc biệt

Nếu chỉ tính giải Đặc biệt, mọi cấu hình không có lần trúng đều có ROI bằng -100% . Khi có đúng một lần trúng, ROI vẫn âm vì chi phí mua vé trong 1 806 ngày lớn hơn khoản thưởng nhận được. Với Rolling Frequency 180, ROI chỉ giải Đặc biệt từ Top-1 đến Top-10 lần lượt là $-100,00\%$, $-30,79\%$, $-53,86\%$, $-65,39\%$, $-72,31\%$, $-76,93\%$, $-80,22\%$, $-82,70\%$, $-84,62\%$ và $-86,16\%$. Ở các mô hình còn lại, các

ngưỡng không có lần trúng đều bằng -100% ; các ngưỡng có một lần trúng có cùng mức ROI theo số vé tương ứng. Không có cấu hình chỉ-Đặc biệt nào có ROI dương.

5.3.5 ROI khi tính toàn bộ cơ cấu giải thưởng

Bảng 5.4 trình bày ROI từ Top-1 đến Top-10 sau khi tính cả các giải thấp hơn. Đây là chỉ số phù hợp hơn với chiến thuật mua vé năm chữ số, vì một vé có thể nhận đồng thời nhiều giải theo các quy tắc khác nhau.

Bảng 5.4. ROI toàn bộ giải thưởng theo số lượng vé mua mỗi ngày

Mô hình	T1	T2	T3	T4	T5	T6	T7	T8	T9	T10
CatBoost	-80,51%	-76,30%	-77,59%	-76,14%	-77,81%	-78,22%	-77,74%	-60,48%	-62,77%	-63,90%
Expanding Frequency	-80,73%	-79,18%	-80,14%	-80,01%	-79,51%	-79,92%	-75,70%	-72,01%	-72,46%	-73,33%
Markov	-78,18%	-78,96%	-79,55%	-79,51%	-79,91%	-80,36%	-79,43%	-62,10%	-64,05%	-65,42%
Rolling Frequency 180	-73,64%	-7,03%	-30,27%	-34,19%	-42,26%	-48,87%	-52,60%	-55,92%	-58,40%	-60,10%
Rolling Frequency 30	-76,97%	-76,91%	-79,03%	-69,60%	-70,92%	-71,52%	-72,03%	-69,13%	-70,28%	-71,06%
Rolling Frequency 365	-79,40%	-79,84%	-80,62%	-80,40%	-80,09%	-70,86%	-72,27%	-72,79%	-73,26%	-73,71%
Rolling Frequency 730	-72,31%	-70,21%	-73,20%	-73,89%	-74,51%	-74,60%	-74,97%	-74,54%	-75,02%	-75,32%
Rolling Frequency 90	-78,63%	-77,63%	-78,26%	-77,71%	-78,67%	-77,02%	-76,89%	-76,95%	-77,53%	-63,26%
Random đều	-75,53%	-75,58%	-76,71%	-78,49%	-78,43%	-50,65%	-53,90%	-57,18%	-59,86%	-61,64%
XGBoost	-76,19%	-72,98%	-74,34%	-73,26%	-73,53%	-74,84%	-75,26%	-75,80%	-75,72%	-70,50%

Cấu hình có ROI cao nhất trong toàn bộ 100 tổ hợp mô hình–ngưỡng là Rolling Frequency 180 với Top-2, đạt $-7,03\%$. Trong 1 806 ngày, cấu hình này mua 3 612 vé, có tổng chi phí 36,12 triệu VND và tổng tiền thưởng 33,58 triệu VND, tương ứng mức lỗ 2,54 triệu VND. Kết quả tốt nhất ở Top-10 cũng thuộc Rolling Frequency 180 với ROI $-60,10\%$: chi phí 180,60 triệu VND, tổng tiền thưởng 72,06 triệu VND và mức lỗ 108,54 triệu VND. Như vậy, việc tính thêm các giải thấp làm giảm mức lỗ so với chiến lược chỉ nhắm Đặc biệt, nhưng không tạo ra lợi nhuận dương.

5.3.6 Các giải khác khi mua Top-10

Bảng 5.5 cho biết tỷ lệ ngày có trúng từng giải khác khi mua mười vé đứng đầu mỗi ngày. Các tỷ lệ này được tính trên 1 806 ngày và phản ánh trực tiếp khả năng thu hồi một phần chi phí thông qua các giải thấp.

Bảng 5.5. Tỷ lệ ngày trúng các giải khác và tiền thưởng khi mua Top-10

Mô hình	G7	G6	G5	G4	G3	G2	G1	Giải khác (VND)	ROI tổng
CatBoost	14,51%	1,05%	0,66%	0,22%	0,00%	0,00%	0,00%	40.200.000	-63,90%
Expanding Frequency	16,00%	1,88%	0,22%	0,28%	0,06%	0,11%	0,00%	48.160.000	-73,33%
Markov	15,23%	1,44%	0,39%	0,11%	0,06%	0,00%	0,00%	37.460.000	-65,42%
Rolling Frequency 180	13,68%	1,83%	1,11%	0,33%	0,06%	0,06%	0,00%	47.060.000	-60,10%
Rolling Frequency 30	14,67%	1,50%	0,61%	0,33%	0,11%	0,11%	0,00%	52.260.000	-71,06%
Rolling Frequency 365	13,73%	1,50%	0,61%	0,33%	0,00%	0,11%	0,00%	47.480.000	-73,71%
Rolling Frequency 730	11,41%	1,50%	0,55%	0,28%	0,06%	0,00%	0,00%	44.580.000	-75,32%
Rolling Frequency 90	13,51%	1,38%	0,55%	0,33%	0,11%	0,00%	0,00%	41.360.000	-63,26%
Random đều	33,11%	2,60%	0,89%	0,39%	0,00%	0,06%	0,00%	44.280.000	-61,64%
XGBoost	14,40%	1,88%	0,39%	0,33%	0,22%	0,00%	0,06%	53.280.000	-70,50%

Random đều có tỷ lệ ngày trúng giải Bảy cao hơn các mô hình còn lại, nhưng đây không phải là bằng chứng về khả năng dự báo giải Đặc biệt; nó phản ánh việc mua mười số ngẫu nhiên bao phủ nhiều hậu tố hai chữ số. XGBoost có tiền thưởng từ các giải khác tương đối lớn, nhưng ROI vẫn âm 70, 50% và không có lần trúng Đặc biệt trong Top-10. Kết quả này cho thấy các giải thấp có thể làm thay đổi mức lỗ quan sát được giữa các chiến lược, song không đảo ngược kết luận về hiệu quả kinh tế.

5.3.7 Đánh giá tổng hợp

Không có mô hình nào đồng thời đạt Top-1, có lần trúng Đặc biệt lặp lại và ROI dương. Lần trúng duy nhất ở một số cấu hình Top- k không đủ để phân biệt mô hình với đường cơ sở Random, đặc biệt khi số ngày kiểm tra dài và có nhiều cấu hình được so sánh. Vì vậy, kết quả của giao thức 2021–2025 không cung cấp bằng chứng về một tín hiệu dự báo ổn định; nó củng cố việc xem giải Đặc biệt là mục tiêu ngẫu nhiên đối với chiến lược đầu tư.

5.4 Thiết kế chiến lược

P3 chuyển xác suất chữ số thành các pool năm vị trí, rồi sinh vé bằng tích Descartes. Ba cấu hình được kiểm thử là $2 \times 2 \times 2 \times 2 \times 2 = 32$ vé, $3 \times 2 \times 2 \times 2 \times 1 = 24$ vé và $3 \times 3 \times 2 \times 1 \times 1 = 18$ vé mỗi ngày. Một nhánh riêng tập trung vào giải Bảy: chọn các

tiền tố đứng đầu ở ba vị trí đầu và thử $m = 1, \dots, 10$ đuôi số đứng đầu ở hai vị trí cuối.

Mỗi vé có giá 10.000 VND. Kết quả được đối sánh với toàn bộ 27 giải năm chữ số trong ngày; một vé có thể nhận nhiều giải hợp lệ. Mức trả trong code backtest là: Phụ Đặc biệt 25.000.000; Khuyến khích Đặc biệt 40.000; giải Nhất 10.000.000; Nhì 5.000.000; Ba 1.000.000; Tư 400.000; Năm 200.000; Sáu 100.000; Bảy 40.000 VND.

Mức trả thưởng dùng trong code backtest không mô phỏng đầy đủ vé giải Đặc biệt 500 triệu VND kèm điều kiện ký hiệu 4/20; vì vậy, các ROI thực nghiệm trong chương được hiểu là ROI của bài toán proxy khớp năm chữ số và các giải phụ được mã hóa.

5.5 Chia tập và chỉ số

Validation 2023–2024 dùng để so sánh ứng viên; final test 2025–2026 chỉ được mở một lần cho đánh giá cuối. Lợi nhuận ngày là


$$\Pi_t = \sum_{g \in G_t} R_g - 10\,000n_t,$$

trong đó G_t là tập giải vé nhận được, R_g là tiền trả của giải và n_t là số vé. ROI bằng tổng lợi nhuận chia tổng chi phí. Cách tính này tránh áp dụng một công thức hòa vốn duy nhất cho các chiến lược có cơ cấu giải khác nhau.


5.6 Kết quả P3

Bảng 5.6. Backtest các cấu hình pool năm chữ số

Fold	Cấu hình	Số ngày	Số vé	Lợi nhuận (VND)	ROI
Validation	32 vé	723	23136	-143.600.000	-62,07%
Validation	24 vé	723	17352	-134.120.000	-77,29%
Validation	18 vé	723	13014	-104.580.000	-80,36%
Final test	32 vé	606	19392	-147.120.000	-75,87%
Final test	24 vé	606	14544	-110.000.000	-75,63%
Final test	18 vé	606	10908	-86.940.000	-79,70%




Hình 5.1. Lợi nhuận tích lũy của các pool trên validation.




Hình 5.2. Lợi nhuận tích lũy của các pool trên final test.

5.7 Chiến lược giải Bẫy theo m


Kết quả theo m được giữ lại như một thí nghiệm độ nhạy. Việc tăng m làm tăng số lựa chọn và chi phí, nhưng không bảo đảm tăng lợi nhuận; do đó, cấu hình tốt nhất phải được khóa từ validation trước khi xem final test.




Hình 5.3. Lợi nhuận tích lũy của chiến lược tập trung giải Bảy trên validation.



Hình 5.4. Lợi nhuận tích lũy của chiến lược tập trung giải Bảy trên final test.



Hình 5.5. Độ nhạy lợi nhuận theo số đuôi m trên validation.



Hình 5.6. Độ nhạy lợi nhuận theo số đuôi m trên final test.

5.8 Diễn giải

Tất cả cấu hình đều có ROI âm trên cả hai giai đoạn. Cấu hình 32 vé có tỷ lệ ngày có ít nhất một lần trúng cao hơn, nhưng chi phí cũng lớn hơn và tổng lợi nhuận vẫn âm. Đây là bằng chứng trực tiếp rằng một cải thiện nhỏ về thứ hạng chữ số trong P2 không chuyển thành lợi thế kinh tế trong cơ chế trả thưởng được mô phỏng.

Chương 6

KẾT QUẢ TỔNG HỢP VÀ THẢO LUẬN

6.1 Từ kiểm định đến dự báo

Phần 1 không tìm thấy phụ thuộc thời gian có hệ thống sau hiệu chỉnh nhiều kiểm định. Vì vậy, mô hình dự báo được xem là phép kiểm tra thực nghiệm về khả năng cải thiện ngoài mẫu, không phải giả định rằng dữ liệu chắc chắn có quy luật.

6.2 So sánh mô hình

Expanding Beta đứng đầu validation, trong khi CatBoost là mô hình học máy tốt nhất. Tuy nhiên chênh lệch giữa Expanding Beta và Uniform trên final test rất nhỏ. Top- k cao ở k lớn một phần do mục tiêu pool có độ phủ nhiều chữ số; không nên diễn giải như mô hình đã dự đoán chính xác một số năm chữ số.

Đối với mục tiêu giải, xác suất trúng một vé cụ thể nhỏ hơn rất nhiều so với xác suất một chữ số xuất hiện trong toàn bộ 27 giải. Vì vậy, báo cáo tách hai mục tiêu và chỉ sử dụng pool prediction để hỗ trợ sinh ứng viên, sau đó đánh giá trực tiếp vé theo kết quả thực tế và quy tắc trả thưởng.

6.3 Ý nghĩa thực tiễn

Lợi nhuận dương trong một giai đoạn không đủ chứng minh lợi thế dài hạn. Nếu kết quả không tái lập ở giai đoạn khác, kết luận phù hợp là hiệu năng chưa ổn định. Cần báo cáo khoảng tin cậy, nhiều giai đoạn rolling và số lần thử chiến lược.

6.4 Giải Đặc biệt và chuyển hướng sang bài toán đầu tư

Về mặt xác suất, vé giải Đặc biệt phải khớp đồng thời năm chữ số và một trong bốn ký hiệu được quay từ 20 ký hiệu. Do đó, xác suất lý thuyết của một vé khớp đầy đủ là

$$\frac{1}{100\,000} \times \frac{4}{20} = \frac{1}{500\,000} = 0,0002\%.$$

Các kết quả thực nghiệm dưới đây chỉ quan sát phần năm chữ số vì dữ liệu chưa lưu trường ký hiệu; xác suất $1/500\,000$ được dùng để diễn giải đúng độ khó của giải thưởng đầy đủ. Thí nghiệm rolling năm năm cho mục tiêu chính xác một số Đặc biệt cung cấp một kiểm tra nghiêm ngặt hơn so với việc chỉ so sánh điểm số xác suất. Trong 5.281 ngày dự đoán, không mô hình nào trúng Top-1; ở Top-10, số lần trúng cao nhất chỉ bằng đúng một lần và đường cơ sở Random đều cũng đạt một lần. Kết quả này không cho thấy mô hình nào vượt qua xác suất nền.

Giao thức cố định huấn luyện trước năm 2021 và kiểm tra trong giai đoạn 2021–2025 cho kết luận nhất quán trên một thiết kế dễ diễn giải hơn. Trong 1 806 ngày kiểm tra, cả mười cấu hình đều có 0 lần trúng Top-1; số lần trúng Top-10 cao nhất cũng chỉ là 1. Rolling Frequency 180 đạt lần trúng đầu tiên ở Top-2 vào ngày 07/09/2021, nhưng không có lần trúng thứ hai. CatBoost và Markov chỉ bắt đầu có một lần trúng từ Top-8; Rolling Frequency 90 chỉ trúng ở Top-10; XGBoost không trúng trong Top-10. Do đó, việc bổ sung mô hình học máy không tạo ra cải thiện thực nghiệm rõ ràng so với các baseline thống kê.

Khi tính toàn bộ cơ cấu giải thưởng, cấu hình tốt nhất là Rolling Frequency 180–Top-2 với ROI $-7,03\%$; khi chỉ tính giải Đặc biệt, ROI tương ứng vẫn âm. Ở Top-10, cấu hình tốt nhất là Rolling Frequency 180 với ROI $-60,10\%$, trong khi XGBoost đạt $-70,50\%$ và Random đều đạt $-61,64\%$. Các giải thấp, đặc biệt giải Bảy, giúp thu hồi một phần chi phí nhưng không tạo ra ROI dương cho bất kỳ mô hình nào.

Về mặt phương pháp luận, dữ liệu không thể chứng minh mệnh đề tuyệt đối rằng mọi cơ chế sinh số là ngẫu nhiên. Tuy nhiên, với dữ liệu quan sát, các kiểm định thống kê, đánh giá walk-forward, so sánh với Random và kết quả lợi nhuận, giả thuyết phù hợp nhất là giải Đặc biệt không chứa tín hiệu ổn định có thể khai thác để dự báo. Vì vậy, trong phạm vi nghiên cứu này, giải Đặc biệt được xem là một biến ngẫu nhiên và không được sử dụng làm mục tiêu tối ưu hóa lợi nhuận riêng lẻ.

Kết luận này dẫn đến thay đổi mục tiêu của P3: thay vì cố dự báo đúng giải cao nhất, chiến thuật được đánh giá như một quyết định phân bổ ngân sách. Một chiến thuật chỉ được xem là có giá trị khi lợi nhuận và ROI được tái lập trên các giai đoạn chưa dùng để lựa chọn cấu hình, đồng thời không phụ thuộc vào một vài lần trúng bất thường.

6.5 Hạn chế

- Cách định nghĩa mục tiêu theo 27 kết quả ảnh hưởng mạnh đến độ khó.
- Nhiều kiểm định và cấu hình làm tăng nguy cơ dương tính giả.
- Final test chỉ phản ánh dữ liệu đã thu thập đến thời điểm báo cáo.
- Lợi nhuận mẫu nhỏ có thể bị chi phối bởi một vài lần trúng.

Chương 7

KẾT LUẬN

Báo cáo đã xây dựng quy trình gồm kiểm định thống kê, mô hình xác suất và backtest chiến lược cho dữ liệu xổ số miền Bắc. Quy trình walk-forward và tách validation khỏi final test giúp hạn chế rò rỉ thông tin.

Các kiểm định không cho thấy bằng chứng mạnh về phụ thuộc vị trí, Markov hoặc phụ thuộc thời gian ở lag 1–30 sau hiệu chỉnh FDR. Một số sai lệch cục bộ trong phân phối chữ số và đuôi số tồn tại, nhưng chưa đủ để suy ra quy luật dự báo tổng quát.

Expanding Beta là mô hình tốt nhất trên validation theo Brier score và log loss; trên final test, lợi thế so với Uniform rất nhỏ. Các mô hình học máy không vượt rõ rệt các baseline xác suất đơn giản.

Kết luận cuối cùng là chưa có bằng chứng đủ mạnh để khẳng định chiến lược có lợi nhuận bền vững. Lợi nhuận của một giai đoạn chỉ là kết quả backtest có điều kiện; cần khóa cấu hình trước, mở rộng final test và kiểm tra khả năng tái lập ở nhiều giai đoạn.

Nghiên cứu không nhằm khuyến khích đặt cược, mà nhằm kiểm tra bằng phương pháp thống kê liệu dữ liệu có chứa tín hiệu ổn định vượt baseline hay không.

Đối với riêng giải Đặc biệt, cần phân biệt mục tiêu khớp năm chữ số với mục tiêu nhận thưởng đầy đủ. Theo cấu trúc vé gồm năm chữ số và một trong bốn ký hiệu được quay từ 20 ký hiệu, xác suất của một vé khớp đầy đủ là $1/(100\,000) \times (4/20) = 1/500\,000 = 0,0002\%$. Thí nghiệm rolling năm năm chỉ quan sát phần năm chữ số, và cho thấy không mô hình nào trúng Top-1 trong 5.281 ngày dự đoán. Kết quả Top-10 cũng không vượt đường cơ sở Random: một số mô hình trúng một lần, trong khi một số mô hình không trúng lần nào; ROI vẫn rất âm. Vì vậy, trong phạm vi dữ liệu và giao thức đánh giá, giải Đặc biệt nên được coi là ngẫu nhiên đối với mục tiêu dự báo một số năm chữ số cụ thể. Đây là kết luận thực nghiệm về khả năng khai thác tín hiệu, không phải khẳng định tiên nghiệm có tính tuyệt đối về cơ chế vật lý của quá trình quay số.

Thí nghiệm bổ sung với dữ liệu huấn luyện đến hết năm 2020 và kiểm tra liên tục trong năm năm 2021–2025 củng cố kết luận trên. Trên 1 806 ngày kiểm tra, không mô hình nào trúng Top-1; không mô hình nào có lần trúng Đặc biệt thứ hai ở bất kỳ ngưỡng Top-1–Top-10. Kết quả tốt nhất về mặt quan sát là Rolling Frequency 180 với một lần trúng ở Top-2, nhưng ROI tính trên toàn bộ giải vẫn là $-7,03\%$; ở Top-10, ROI tốt nhất là $-60,10\%$. CatBoost và XGBoost không tạo ra lợi thế đáng kể: CatBoost chỉ có một lần trúng từ Top-8, còn XGBoost không trúng trong Top-10.

Các giải khác có đóng góp đáng kể vào tiền thưởng, đặc biệt khi mua Top-10, nhưng chỉ làm giảm mức lỗ chứ không làm thay đổi dấu của ROI. Vì vậy, dữ liệu không cho thấy bất kỳ mô hình hoặc số lượng vé nào có khả năng tạo lợi nhuận bền vững. Kết luận phù hợp là chưa quan sát được tín hiệu có thể khai thác ngoài mẫu, chứ không phải khẳng định tuyệt đối rằng mọi kết quả xổ số đều có thể chứng minh là ngẫu nhiên bằng một thí nghiệm hữu hạn.

Từ kết luận đó, nghiên cứu chuyển sang chiến thuật đầu tư với ngân sách và cơ cấu giải được xác định trước. Mục tiêu không còn là tìm một số Đặc biệt “chắc chắn”, mà là kiểm tra liệu việc phân bổ vé theo xác suất dự báo có tạo ra lợi nhuận vượt đường cơ sở hay không. Các kết quả P3 hiện tại chưa cho thấy ROI dương ổn định; vì vậy chưa có cơ sở để khuyến nghị một chiến thuật đặt cược có lợi nhuận bền vững.

TÀI LIỆU THAM KHẢO

- [1] Benjamini, Y. and Hochberg, Y. (1995), Controlling the false discovery rate, *JRSS Series B*, 57(1), 289–300. [2] Gelman, A. et al. (2013), *Bayesian Data Analysis*, 3rd ed., CRC Press. [3] Bishop, C. M. (2006), *Pattern Recognition and Machine Learning*, Springer. [4] Breiman, L. (2001), Random forests, *Machine Learning*, 45, 5–32. [5] Chen, T. and Guestrin, C. (2016), XGBoost: A scalable tree boosting system, *Proceedings of KDD*. [6] Prokhorenkova, L. et al. (2018), CatBoost: unbiased boosting with categorical features, *NeurIPS*. [7] Gneiting, T. and Raftery, A. E. (2007), Strictly proper scoring rules, prediction, and estimation, *JASA*. [8] Dawid, A. P. (1982), The well-calibrated Bayesian, *JASA*. [9] Repository KQXS, nhánh lottery-update, GitHub, truy cập 09/2026. [10] Repository template qh25-data-mining/report, GitHub, truy cập 09/2026.